📝 Parecer de Avaliação de Projeto de TCC

Informações

Campo	Valor
Componente curricular	Projetos em Ciência de Dados I
Discente	Pedro Henrique Medeiros Vieira
Título do projeto	Entity Matching em produtos de supermercado com Small Language Models fine-tuned
Docente orientador	Prof. Dr. Hilton Martins de Brito Ramalho
Avaliador	Prof. Jorge Henrique Norões Viana
Data da avaliação	2026-08-15
Modalidade indicada	Artigo científico

---

1. Apreciação Geral

O projeto propõe desenvolver e avaliar um sistema de Entity Matching (EM) para descrições de produtos de supermercado, baseado no fine-tuning supervisionado de um Small Language Model (SLM) sob formulação de Cross-Encoder, sobre os dados reais do projeto ALTA/CNPq. O problema está bem delimitado e é genuinamente relevante: sem resolução de entidades, os registros de preços coletados nos três estados permanecem incomparáveis, e a solução proposta tem retorno direto sobre a infraestrutura analítica do projeto. A lacuna científica está bem estabelecida (matching de produtos em português brasileiro, com o perfil de ruído próprio dos sistemas de PDV, é cenário efetivamente pouco explorado). O texto está bem escrito e o detalhamento metodológico é maior do que se costuma ver nesta etapa.

Três decisões merecem destaque. A primeira é o tratamento da ausência de *ground truth* como parte da contribuição, e não como limitação a ser minimizada. A segunda é a delimitação prévia dos baselines; fixar o conjunto de comparação e o protocolo de avaliação antes de treinar qualquer modelo é ponto forte importante. A terceira é o planejamento da redação incremental ao longo das Semanas 1 a 9, com checkpoint de 60% do texto na Semana 8; é uma boa ideia que evita se empolgar na parte boa (“codar”). Também é uma boa ideia de planejamento, considerar a submissão a conferência nacional desde já, o que é especialmente pertinente na modalidade de artigo científico.

O ponto mais frágil da proposta, no estado atual, é a justificativa da escolha do modelo-base, tratada adiante entre as recomendações.

---

2. Factibilidade

O trabalho é factível no horizonte de dezesseis semanas, com ressalvas contornadas. Os dados já existem e são coletados de forma contínua pelo projeto ALTA, o que elimina o risco de obtenção; a infraestrutura computacional descrita é folgada para um modelo de três bilhões de parâmetros.

O caminho crítico é a construção do “padrão-ouro”. As Semanas 3 a 5 concentram a anotação de 300 a 500 pares, o teste-reteste e a redação da Introdução, e qualquer deslize nesse trecho se propaga por todo o restante do cronograma. Por fim, a caracterização quantitativa da base é ainda planejada, e não realizada, o que é norma para o estágio atual. Mas tem baixo custo e alto retorno: antecipá-lo reduziria a incerteza sobre volume, sobreposição de produtos entre lojas e granularidade do dicionário canônico.

---

3. Sugestões e Recomendações para a Continuidade

1. **Justificar a escolha do modelo-base:** A adoção do LLaMA 3.2 3B é a decisão de maior consequência do trabalho e é hoje a menos justificada. A Tabela 2 ainda é insuficiente: ela compara os três modelos considerados, mas não explica por

que apenas esses três foram considerados. Toda escolha precisa ser justificada, preferencialmente com apoio na literatura. Critérios práticos como tamanho e licença são importantes, mas existem muitos modelos nessa escala de parâmetros e é preciso dizer por que este especificamente. Há ainda dois pontos a enfrentar. Primeiro, modelos na casa de 10B a 30B, quantizados e/ou com arquitetura de mistura de especialistas (MoE), também rodam em infraestrutura local e deveriam entrar na comparação, nem que seja para serem descartados com argumento, até porque, a infraestrutura disponível daria conta deles. Se a razão for não tornar a solução dependente de infraestrutura robusta, dada a continuidade do projeto ALTA, esse é um bom argumento e deve estar escrito. Não há nada de errado com a escolha, mas ela apenas precisa ser melhor fundamentada.

2. **Reduzir o risco de vazamento na anotação:** O conjunto de teste será anotado pelo mesmo autor que constrói o pipeline. Sendo o anotador a mesma pessoa que conhece a ferramenta de geração e as heurísticas de supervisão distante, é provável que critérios do treino vazem involuntariamente para os rótulos de teste. Recomenda-se envolver um segundo anotador, ainda que sobre um subconjunto mais restrito e sem acesso ao pipeline, o que permitiria reportar concordância inter-anotadores (Cohen's Kappa) de fato, mantendo o teste-reteste como medida complementar.
3. **Formalizar as autorizações e avaliar a propriedade intelectual:** O trabalho depende de recursos de uma empresa privada. É importante confirmar formalmente que a empresa está ciente e autoriza esse uso no âmbito de um TCC. Pela mesma razão, a promessa de abertura do repositório e do conjunto de teste anotado deve ser confirmada não apenas com os coordenadores do ALTA/CNPq, mas também com a empresa. Vale ainda avaliar, com o orientador, se a solução tem potencial de proteção por patente ou registro; havendo esse potencial, a decisão sobre o que abrir e quando precisa ser tomada antes da defesa, e não depois.
4. **Incluir um diagrama do pipeline e explicar os procedimentos menos usuais:** O encadeamento entre blocagem lexical, geração de candidatos, reranqueamento pelo Cross-Encoder e roteamento no pipeline progressivo é hoje descrito apenas em texto, distribuída por quatro subseções; um diagrama único tornaria a arquitetura mais fácil de entender. Além disso, o texto mobiliza vários procedimentos não usuais para o leitor típico da área de CDN (LoRA e precisão bf16, supervisão distante, mineração de negativos difíceis, blocagem, fine-tuning com objetivo duplo), entre outros que merecem ao menos uma explicação mínima de funcionamento ou a indicação de onde o leitor encontra os detalhes.
5. **Sustentar empiricamente a insuficiência dos métodos clássicos:** A Seção 1 afirma que os métodos tradicionais de comparação de strings e os embeddings genéricos "foram analisados" e se mostram insuficientes, sem esclarecer se essa análise ocorreu no âmbito deste trabalho ou previamente, no projeto ALTA. Se houver resultados preliminares, reportá-los, ainda que de forma sumária, fortaleceria a motivação da proposta. Do contrário, a afirmação deve ser reapresentada como hipótese a ser testada pelos baselines da Seção 4.4.

---

4. Conclusão e Veredicto

O projeto atende aos requisitos do componente curricular: o problema está bem delimitado, a solução proposta é pertinente e factível, os dados e recursos previstos são acessíveis e adequados, e o percurso planejado pode ser concluído em Projetos em Ciência de Dados II (TCC). As recomendações 1 e 2 são as de maior peso e devem ser incorporadas ao trabalho, mas não condicionam a aprovação nesta etapa. Recomenda-se a aprovação.

> ***Resultado:*** *Aprovado* ***Nota:*** *10,0 (dez)*